VAE, evaluación y Model Card

Estudiante: _____

Docente: Edwin Ramón José Nolasco · UASD · INF-8239-C2

Fecha: 10 de octubre de 2026 · Repositorio: https://github.com/rhaynel19/VAE-evaluaci-n-y-Model-Card

1. Propósito y alcance

El ejercicio consolida la implementación y evaluación de un autoencoder determinista (AE) y un autoencoder variacional (VAE). Se estudian reconstrucción y, para el VAE, muestreo e interpolación en el espacio latente. El producto es una demostración académica, no un sistema para producción ni para decisiones sobre personas.

2. Datos y diseño experimental

Se usó Fashion-MNIST, cargado mediante Keras, con imágenes monocromáticas de 28 × 28 píxeles normalizadas a [0, 1]. Se utilizaron 60,000 imágenes de entrenamiento y 10,000 de prueba; las etiquetas no se emplearon. La semilla fue 42, el lote 256 y el optimizador Adam con su tasa predeterminada. El AE reservó 10% del entrenamiento para validación y usó parada temprana; completó 6 épocas. El VAE completó 8 épocas sin partición de validación en el script. Entorno: Python 3.12.14, TensorFlow 2.21.0, Windows-11-10.0.26300-SP0, dispositivo /physical_device:CPU:0.

3. Baselines: arquitectura y capacidad

AE: Flatten(784) → Dense(16, ReLU) → Dense(784, sigmoid) → reshape; espacio latente de 16 dimensiones y 25,888 parámetros. VAE: codificador Flatten → Dense(128, ReLU) → media y log-varianza (2 dimensiones); decodificador Dense(128, ReLU) → Dense(784, sigmoid) → reshape. El VAE tiene 100,996 parámetros en el codificador, 101,520 en el decodificador y 202,516 en total.

4. Reconstrucción en el conjunto de prueba

Modelo	MAE ↓	MSE ↓	BCE suma/imagen	KL/imagen
AE	0.0820	0.0203	240.55	—
VAE (media posterior)	0.1086	0.0330	266.99	6.30

VAE: reconstrucción + KL = 273.29 por imagen. MAE/MSE son promedios por píxel; BCE se suma por imagen.

Evaluación, costo y decisión

5. Reconstrucción, muestreo e interpolación

La métrica del VAE se calculó decodificando la media posterior de forma determinista; no es una estimación Monte Carlo del ELBO. El entrenamiento del VAE optimiza reconstrucción + divergencia KL. Por ello, los valores de pérdida del AE y del VAE no son directamente comparables como si fueran el mismo objetivo. El AE obtuvo menor MAE/MSE de reconstrucción en esta prueba. Las imágenes de originales, reconstrucciones AE/VAE y muestras generadas están en reports/ae_vae_panel.png. La interpolación lineal entre puntos fijados manualmente está en reports/interpolation.png.

6. Fidelidad, diversidad y proximidad

Se generaron 128 muestras para el análisis. La MAE media entre 4,096 pares muestreados fue 0.1567. La MAE media a la muestra de referencia más cercana fue 0.0768 (mínimo 0.0370), usando un subconjunto de 1,000 imágenes de entrenamiento. Son distancias pixelarias: no miden calidad perceptual, diversidad semántica ni cobertura por clase. La búsqueda no incluye todos los datos y no prueba privacidad o memorización.

7. Costo, memoria y almacenamiento

El ajuste tardó 14.08 s para el AE y 27.78 s para el VAE, midiendo solo el ajuste. La huella teórica float32 de pesos fue 103,552 bytes para el AE y 810,064 bytes para el VAE. Es el número de parámetros multiplicado por cuatro; no mide el pico de RAM. Los archivos guardados ocupan 338,597 bytes para el AE y 852,962 bytes para el codificador y decodificador VAE.

8. Limitaciones y decisión final

Se evaluó una sola semilla y una configuración; no se calcularon intervalos de confianza, FID, utilidad downstream ni pico de memoria. Fashion-MNIST contiene imágenes pequeñas y monocromáticas. Para reconstrucción en esta corrida se prefiere el AE por su MAE/MSE menor, menor cantidad de parámetros y menor tiempo de ajuste. El VAE se conserva para estudiar muestreo e interpolación con regularización latente. La decisión se limita a este experimento y no declara superioridad general.

Uso responsable y reproducibilidad

9. Uso responsable de inteligencia artificial

Se utilizó Copilot como apoyo para revisar el proyecto, mejorar la persistencia de métricas, proponer pruebas y preparar documentación, notebook e informe. El estudiante debe revisar el material, entender y poder defender el código y las conclusiones, y responde por lo entregado. La generación sintética no garantiza privacidad ni anonimato. No se deben inventar fuentes ni redistribuir MovieLens.

10. Pruebas y reproducción

La suite local finalizó con 7 pruebas aprobadas y Ruff sin errores. El notebook de evaluación fue ejecutado: 4 celdas de código, sin errores. El paquete contiene src, tests, reports, Model Card, declaración de IA, README, requirements.txt y notebook.

```
uv sync --extra cpu
uv run python scripts/check_runtime.py
uv run python scripts/train_ae_vae.py --epochs-ae 6 --epochs-vae 8
uv run pytest -q
uv run ruff check .
```

Referencias del proyecto

Repositorio: https://github.com/rhaynel19/VAE-evaluaci-n-y-Model-Card. Evidencia experimental: reports/training_metrics.json, reports/ae_vae_panel.png e reports/interpolation.png. Consulte MODEL_CARD.md y AI_USE_DECLARATION.md para detalles ampliados.

Estudiante: completar el nombre y confirmar personalmente el contenido antes de entregar.